Algoritmos de Gran Escala

$Andrea\ García\ Tapia,\ Andrea\ Frenández\ ,\ Mario\ Becerra$ $24\ de\ mayo\ de\ 2015$

Índice

1.	Aná	ilisis Exploratorio de Datos	2
	1.1.	Descripción del Dataset	2
2.	Mod	delos de clasificación	4
	2.1.	Regresión Logística Regularizada	4
	2.2.	Máquina de Soporte Vectorial en Paralelo	6
3.	. Problemas		8
	3.1.	Implementación del Cluster	8
	3.2.	Paralelización de SVM	8

1. Análisis Exploratorio de Datos

México ha tenido un incremento en los costos económicos de desastres asociados a fenómenos hidrometeorológicos, huracanes e inundaciones, entre otros. En 2010 se presentaron las mayores pérdidas económicas en la historia del país por fenómenos hidrometeorológicos y geológicos; en total se perdió el 0.8 % del PIB y se estima que, una vez calculado en su totalidad, el daño por las tormentas tropicales Ingrid y Manuel en 2013 supere los valores anteriores.

Una pregunta clave que todavía no se contesta en México es si este incremento en daños y pérdidas se debe a un cambio en la distribución de los desastres o a observaciones atípicas. El Sistema de Protección Civil (SINAPROC) define desastre "al resultado de la ocurrencia de uno o más agentes perturbadores severos y o extremos, concatenados o no, de origen natural o de la actividad humana, que cuando acontecen en un tiempo y en una zona determinada, causan daños y que por su magnitud exceden la capacidad de respuesta de la comunidad afectada"; sin embargo no esta definida qué es la capacidad de respuesta de la comunidad afectada ni existen indicadores. Nuestro sistema es reactivo y las reglas de operación no son muy claras. EL Panel Intergubernamental de Cambio Climático (IPCC) prevee un aumento en la frecuencia e intensidad de los desastres hidrometeoroógicos debido al cambio climático.

Actualmente el SINAPROC funciona de la siguiente manera: cuando ocurre un desastre el Gobierno Estatal solicita una evaluación al Gobierno Federal. Este a su vez solicita al Servicio Meteorológico Nacional (SMN), al Sismológico, Comisión Nacional Forestal (CONAFOR) o al Centro Nacional de Prevención de Desastres (CENAPRED), dependiendo el tipo de desastre, la corroboración del evento. Una vez corroborado el Gobierno Federal decide si lo declara o no . Si lo declara tiene tres opciones: Contingencia Climática, Desastre, Emergencia o una combinación de las últimas dos. Esta declaratoria hace toda la diferencia ya que si no es declarado, el evento solo recibe ayuda de protección civil local. Por el contario si lo declaran desastre (contingencia climática, desastre o emergencia) se activa el programa de reconstrucción del FONDEN, el programa de apoyos de SAGARPA (CADENA) y diversos programas de apoyo social como el programa de Empleo Temporal de SEDESOL. Es por ello que es tan importante tener reglas claras. Este proyecto busca clarificar las reglas del proceso de declaratoria de desastres naturales y encontrar un modelo que ayude al Gobierno Federal acelerar los procesos de decalratoria, ya que actuar de manera oportuna es vital.

Los datos fueron obtenidos del Centro Nacional de Prevención de Desastres (CENAPRED) para los desastres Hidrometeorológicos de 2000-2010. La base se llama Impacto Socio Económico y es con la que realizan la serie anual de los libros con el mismo nombre. Se unió con la base Marginación de CONEVAL y con una base de Riesgos realizada por el Centro Mario Molina (CMM). La base de Riesgos fue realizada para 5 peligros (huracán, inundación, sequía, incendio forestal, deslave) calculados a partir de las características geofísicas del país y las tasas de retorno de los desastres.

1.1. Descripción del Dataset

La base se conforma de 25 variables, entre las cuales hay características geográficas (riesgos), características socioeconómicas de la población y características del evento.

Tipo de	
declaratoria	Tipo de declaratoria, según el diario oficial de
(dependiente)	la federación (1 si fue declarado, 0 eoc))
(acpendience)	Porcentaje de población analfabeta de 15 años
ANAL	o más
7.1.7.2	Porcentaje de población sin primaria completa
SPRI	de 15 años o más
5.11	Porcentaje de ocupantes en viviendas sin
OVSDS	drenaje ni servicio sanitario exclusivo
0.000	Porcentaje de ocupantes en viviendas sin
OVSEE	energía eléctrica
	Porcentaje de ocupantes en viviendas sin agua
OVSAE	entubada
0.00.00	Porcentaje de viviendas con algún nivel de
VHAC	hacinamiento
*****	Porcentaje de ocupantes en viviendas con piso
OVPT	de tierra
-	Porcentaje de población en localidades con
PL<5000	menos de 5 000 habitantes
	Porcentaje de población ocupada con ingreso
PO2SM	de hasta 2 salarios mínimos
IM	Índice de marginación
GM	Grado de marginación
Sum_POBTOT	Población total
R_Inun	Riesgo de inundación
R_Hur	Riesgo de huracán
R_Des	Riesgo Deslizamiento
R_Seq	Riesgo de sequía
R_IF	Riesgo de incendio forestal
R_Den	Riesgo de dengue
	Número de municipios afectados por el
Num Mun	desastre en cuestión
Fecha de Inicio	Fecha de inicio del desastre
Fecha de Fin	Fecha de fin del desastre
Año	Año de ocurrencia del desastre
Duración	Duración del desastre en días
Clave del	
Estado	Clave de la entidad federativa según INEGI
Municipio	Nombre del municipio del registro en cuestión
Tipo de	The state of the form of the state of the st
ripo de	Tipo de fenómeno: Iluvia, inundación,

Figura 1: Descripción de variables en la base de datos.

Se dividió el conjunto de datos (4750 observaciones con 25 variables) en datos de entrenamiento (70 %) y de prueba (30 %). La distribución por Grado de Marginación nos muestra que los grados altos tienen mas declaratorias.

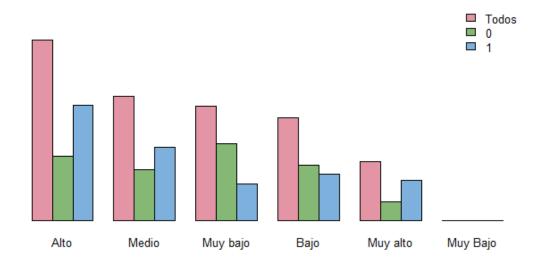


Figura 2: Distribución por grado de marginación.

En cuanto al tipo de fenómeno la mayor parte de las declaratorias se concentran en lluvias y sequías.

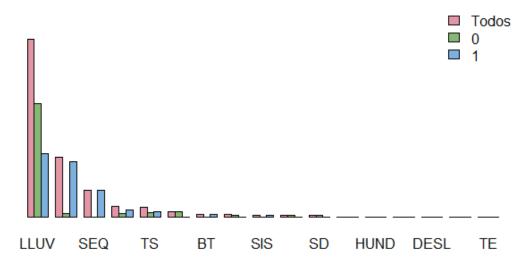


Figura 3: Distribución por tipo de fenómeno.

2. Modelos de clasificación

A continuación se presentan los resultados de los dos clasificadores utilizados para los datos: regresión logística regularizada y máquina de soporte vectorial.

2.1. Regresión Logística Regularizada

Se utilizó el método de *elastic net*, que es una regresión logística con más parámetros de regularización. Estos parámetros se escogen a través de validación cruzada.

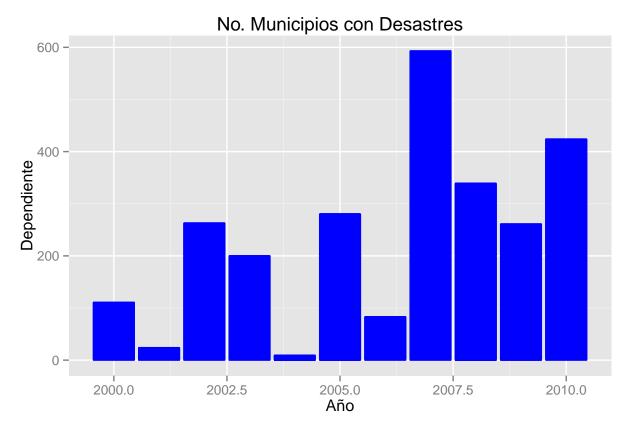


Figura 4: Municipios con desastres.

	0	1
0	254	158
1	354	592

Cuadro 1: Matriz de confusión de regresión logística

	cm\$byClass
Sensitivity	0.4177632
Specificity	0.7893333
Pos Pred Value	0.6165049
Neg Pred Value	0.6257928
Prevalence	0.4477172
Detection Rate	0.1870398
Detection Prevalence	0.3033873
Balanced Accuracy	0.6035482
Daraneed Heedracy	0.0000102

Cuadro 2: Evaluación del modelo con regresión logística.

La tasa de clasificación de incorrectos fue de 0.38, la matriz de confusión se puede ver en el cuadro 4.

2.2. Máquina de Soporte Vectorial en Paralelo

[1] "intercepto"

[1] 0.09747292419257945

Cuadro 3: Matriz de confusión de SVM

Generamos las métricas con las que se evalúa el desempeño de la regresión logística pero para el SVM.

	cm2\$byClass
Sensitivity	0.5131578947368421
Specificity	0.74133333333333333
Pos Pred Value	0.6166007905138340
Neg Pred Value	0.6525821596244131
Prevalence	0.4477172312223859
Detection Rate	0.2297496318114874
Detection Prevalence	0.3726067746686304
Balanced Accuracy	0.6272456140350877

Cuadro 4: Evaluación del modelo con SVM.

Se modificó el código pseudodistribuido de la MSV de manera que se capturara la información de monitoreo del método y fuera posible explorarla.

Los resultados de clasificación con la máquina de soporte vectorial fueron mejores que con la regresión logística regularizada. La tasa de clasificación fue menor.

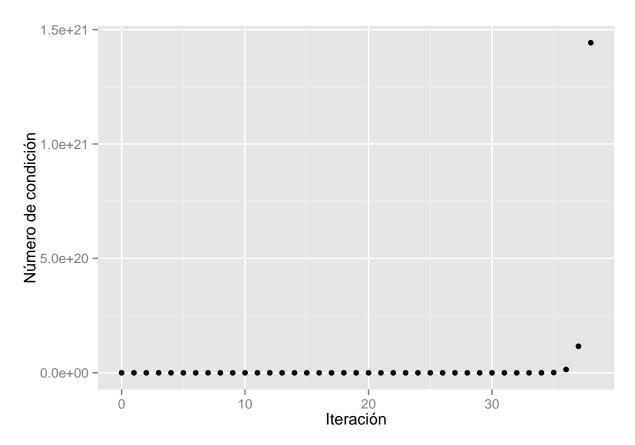


Figura 5: Iteraciones y el número de condición.

3. Problemas

Durante la elaboración de este proyecto nos enfrentamos a diversos problemas.

3.1. Implementación del Cluster

No entendíamos cómo funcionaba el NFS server:

- Al utilizar dos carpetas con nombres distintos, es decir mirrorNFS y carpetaNodo, no sabíamos que era necesario cerrar el loop y correr mpirun en el master desde carpetaNodo.
- Cuando intentamos tener un cluster en nuestras computadoras, con las diferentes versiones y distribuciones de Linux y una computadora MAC, había muchos errores.
- La versión de MPI se actualizó mientras hacíamos las tareas y con un update tuvimos que desinstalar y reinstalar todo de nuevo.
- En realidad, todos los problemas por el NFS se solucionaron cuando entendimos que éste era solamente una manera de pegarle al master los esclavos pero que master siempre considera que está corriendo todo en sus versiones.

Compilación de archivos:

- Las librerías de Lapack, ATLAS, BLAS y las librerías de matemáticas no se cargan en mpicc automáticamente para la distribución de Linux que usamos (Ubuntu, 14.04, unity). Nos tardamos mucho en entender los mensajes de compilación.
- En general, aprender a utilizar c para adaptar los códigos en la tarea 3 fue muy problemático.

3.2. Paralelización de SVM

- Nos pasó lo mismo que con mpi: la versión y localización de R en master y en cada uno de los nodos debe ser exactamente la misma para todas las computadoras en el cluster.
- La instalación de rmpi es muy problemática. Debes de realizar¹:

```
sudo apt-get install libcr-dev mpich2 mpich2-doc
R
install.packages('Rmpi')
install.packages('snow')
```

- Primero, intentamos con Rmpi. Sin embargo, fue muy difícil debuggear e intentar paralelizar el proceso. Lo que nos pasaba es que podíamos prender el cluster en el master pero freezeaba. Cuando leimos diferentes foros de ayuda, resultó que este es uno de los errores más comunes pero puede tener muchas causas. Eventualmente, al poner la bandera de manual=T en el comando para iniciar el cluster, si se podía pero teníamos que ir a cada nodo y ejecutar el script de R generado en cada uno. Esto no escala.
- Después, logramos correrlo en mpi. Sin embargo, no sabíamos porqué estaba repitiendose el proceso tantas veces como procesadores teníamos.

¹Gracias al equipo de Liliana, Gabriel y David.

```
user@pc01:/carpetaNodo$ mpirun -np 10 -bind-to core:overload-allowed -hostfile hostfiles R --slave
 ARNING: a request was made to bind a process. While the system upports binding the process itself, at least one node does NOT upport binding memory to the process location.
This usually is due to not having the required NUMA support installed
on the node. In some Linux distributions, the required support is
contained in the libnumactl and libnumactl-devel packages.
This is a warning only; your job will continue, though performance may be degraded.
                                       |rcx1|
|rcx1|
|rcx1|
                                                                                                                                                                               mu
2.5000e+05
2.5000e+05
2.5000e+05
2.5000e+05
         |F|
5.3806e+07
5.3806e+07
                                       |rcx1|
|rcx1|
5.3348e+07
5.3348e+07
                                                                                                                         |f4|
4.9500e+06
4.9500e+06
                                                                                                                                                    obj
2.2813e+11
                                                                                                                                                     2.2813e+11
2.2813e+11
                                                                                                                                                                                2.5000e+05
2.5000e+05
1.5431e+05
1.5431e+05
                                       5.3348e+07
                                                                                                                          4.9500e+06
                                                                                                                                                                                                            3.3162e-01
                                      5.3348e+07
3.5657e+07
                                                                   5.9000e+04
3.9435e+04
3.9435e+04
                                                                                              4.9500e+06
3.2720e+06
                                                                                                                         4.9500e+06
2.5040e+06
2.5040e+06
                                                                                                                                                     2.2813e+11
1.0170e+11
                                                                                                                                                                                                           3.3162e-01
4.8945e-01
                                                                                                                                                                                                                                      3.3567e+03
3.4859e+03
3.4859e+03
                                       3.5657e+07
                                                                                                                                                                                                           4.8945e-01
4.8945e-01
                                                                                              3.2720e+06
                                                                                                                                                      1.0170e+11
```

```
3.4480e-13
3.4480e-13
3.4480e-13
3.5753e-13
    3.6139e-06
3.6139e-06
                                                                                                                                                                1.8326e-07
1.8326e-07
1.8326e-07
                                                                                                                                       5.8842e+03
                                                                                  2.5554e-06
                                                         9.3354e-10
8.0976e-10
    3.6139e-06
1.5196e-06
                                                                                                                                     -5.8842e+03
   'intercepto
  -0.243801652892636
1.5196e-06 3.57
                                                         8.0976e-10 1.0745e-06 1.0745e-06
8.0976e-10 1.0745e-06 1.0745e-06
                           3.5753e-13
3.5753e-13
                                                                                                                                     -5.8842e+03
    1.5196e-06
                                                                                                                                    -5.8842e+03 6.7167e-08
  -0.243801652892636
1.5196e-06 3.5753e-13 8.0976e-10 1.0745e-06 1.0745e-06 -5.8842e+03 6.7167e-08 9.9950e-01 1.3479e+15
"intercepto"
  -0.243801652892636
"intercepto"
"intercepto"
-0.243801652892636
"En entrenamiento"
0.03099173553719008
"En prueba"
0.01176470588235294
"En entrenamiento"
"En entrenamiento"
"En entrenamiento"
0.03099173553719008
0.03099173553719008
"En prueba"
0.01176470588235294
"En entrenamiento"
"En prueba"
0.01176470588235294
 0.03099173553719008
"En prueba"
0.01176470588235294
  user@pc01:/carpetaNodo$
```

- Probamos muchísimas cosas y nada funcionaba. Entonces, decidimos mejor tirar a la basura y cambiar de estrategia.
- Lo que nos funcionó mejor fue utilizar snow directo y mejor controlar el cluster desde ahí. Un ejemplo funcional para prenderlo de manera interactiva fue (con una sesión en R en carpetaNodo en el master):

```
library(snow)

# Prendes el cluster

cl <- makeSOCKcluster(c("slave05","localhost"))

# clusterApply funciona como apply pero mandas el objeto cluster,

# x *para iterar*, la funcion(suma, para ejemplificar) y parametros adicionales

clusterApply(cl, 1:2, get("+"), 3)

# clusterEvalQ permite enviar comandos a ejecutar en cada nodo para la

# sesion de R abierta en cada uno

clusterEvalQ(cl, library(boot))
```

```
# detenemos el cluster
stopCluster(cl)
```

Para poder conectar bien snow, el único cambio que hay que realizar es completar la conexión de dos vías entre master y esclavos, es decir, que todos vean a todos con el mismo alias. Por ejemplo, en la master (pc01) y en el esclavo (pc05):

```
- ssh mpi_user@148.205.39.111
mpi_user@148.205.39.111's password:
welcome to Ubuntu 14.04.2 LTS (cMU/Linux 3.13.0-46-generic x86_64)

* Documentation: https://help.ubuntu.com/

Last login: Mon May 25 00:11:30 2015 from 187.189.157.1
mpi_user@pc01:-S WI#H1 P/#P/^C
mpi_user@pc01:-S cat /etc/hosts
127.0.1 localhost
127.0.1.1 pc01

# The following lines are desirable for IPv6 capable hosts
::1 ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-localnet
ff00::1 ip6-allnodes
ff00::1 ip6-allnodes
ff00::1 ip6-allnodes
ff00::2 ip6-allnodes
ff00::3 ip6-localnet
ff00::3 ip6-localnet
ff00::1 sof-mcastprefix
ff00::1 sof-mcastp
```

Figura 6: /etc/hosts en PC01.

Figura 7: /etc/hosts en PC05.

• Esta forma nos permitió dejar de utilizar mpirun y poder manipular el cluster desde R. Por esto, al final el llamado a svm en paralelo es vía Rscript, desde el master y en carpetaNodo:

Rscript Script.R

Los resultados se muestran a continuación

```
_user@pc01:/carpetaNodo$ Rscript Script.R
ding required package: methods
Attaching package: 'snow'
   he following objects are masked from 'package:parallel':
             clusterApply, clusterApplyLB, clusterCall, clusterEvalQ,
clusterExport, clusterMap, clusterSplit, makeCluster, parApply,
parCapply, parLapply, parRapply, parSapply, splitIndices,
stopCluster
                                                                  |rcx1|
1.6657e+08
8.2679e+07
4.1339e+04
2.0670e+01
                                                                                                                    |rb|
1.6200e+05
8.0412e+04
4.0206e+01
2.0103e-02
                                                                                                                                                                                                                  5.7037e+06
9.3484e+05
5.9177e+05
                                                                 2.0670e+01
1.0335e-02
5.1674e-06
2.5837e-09
1.2915e-12
2.3945e-13
1.3540e-13
6.8423e-14
3.7676e-14
2.5546e-14
1.2859e-14
1.2859e-14
1.1558e-14
                                                                                                                    2.0103e-02
1.0052e-02
4.9570e-09
1.1440e-09
2.6919e-10
2.8566e-10
3.3505e-10
3.2823e-10
2.3144e-10
3.8213e-10
                                                                                                                    2.0452e-10
3.0972e-10
3.0921e-10
2.7665e-10
3.7835e-10
3.1981e-10
2.9123e-10
3.2809e-10
2.4801e-10
2.9967e-10
3.8677e-10
4.2468e-10
4.2468e-10
6.1813e-10
6.1813e-10
5.7723e-10
4.3655e-10
3.5655e-10
3.8635e-10
3.8833e-10
                                                                                                                                                                                                                  3.8370e+02
2.5756e+02
1.7240e+02
                                                                                                                                                                                                                                                                                                                  1.9340e+00
1.2512e+00
8.3736e-01
5.3545e-01
3.8343e-01
2.8351e-01
                                                                 1.2265e-14
1.2254e-14
1.2791e-14
1.2333e-14
1.2684e-14
1.2774e-14
1.1995e-14
1.2384e-14
1.2384e-14
1.3350e-14
1.3471e-14
1.3482e-14
1.3482e-14
1.5471e-14
1.5471e-14
1.5471e-14
1.5471e-14
1.5471e-14
1.5471e-14
1.5471e-14
               0.3429602888086642
                       n prueba"
3608247422680412
                  ser@pc01:/carpetaNodo$
```

Figura 8: STOUT en PC01 de SVM en paralelo.

Para revisar que el trabajo se estaba realizando en master y en nodos, prendimos un htop en el master y el esclavo:

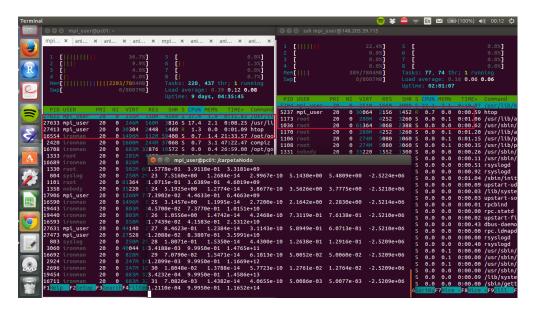


Figura 9: Revisión del proceso en los esclavos y en master.